



Statistic Beans: 統計学豆知識

不应错过的统计学基础知识

作者：在时

时间：2026/3/4

版本：0.3ed Typeset with L^AT_EX

不要以为抹消过去，重新来过，即可发生什么改变。——比企谷八幡

To my friends.

目录

第 1 章	写在前面	1
1.1	本书内容	1
1.2	记录契机	1
1.3	阅读建议	2
第 2 章	数据与统计量	3
2.1	数据一定是数字吗?	3
2.2	统计量是什么?	3
2.3	统计 = 数据 + 统计量 + 统计推断	4
第 3 章	完整的统计过程	5
3.1	提出问题	5
3.2	统计设计	5
3.3	样本数据采集——抽样方式与最佳组数	5
3.4	数据的整理与描述	6
3.5	计算与分析数据	6
3.6	完整的统计步骤	7
第 4 章	数据的可视化与描述	9
4.1	使用图展示数据	9
4.1.1	二维图	9
4.1.1.1	直方图	9
4.1.1.2	折线图	10
4.1.1.3	箱型图	10
4.1.1.4	散点图	11
4.1.2	三维图	12
4.1.3	高维度的降维显示	12
4.2	使用统计量描述数据	12
4.2.1	常用统计量	12
4.2.2	各个分布的统计量	13
第 5 章	概率与分布	15
5.1	概率为 0 就是不可能事件吗?	15
5.2	什么是分布?	15
5.3	标准正态分布	16
5.4	离散型随机变量及其分布	17
5.4.1	0-1 分布	17
5.4.2	二项分布	18
5.4.3	泊松分布	18
5.5	自由度	19
第 6 章	假设检验：从统计量到结论	21
6.1	假设检验与 p 值解读	21

6.2	置信区间	21
6.3	t 检验：关注“平均值”的差异	22
6.4	χ^2 (卡方) 检验：关注“数量/频率”的分布	22
6.5	非技术用语的假设检验总结模板	23
第 7 章	方差分析	25
7.1	前置知识-方差分析在“分析”什么	25
7.2	单因素方差分析	25
7.3	双因素方差分析	26
7.4	多因素方差分析	26
第 8 章	线性回归	27
8.1	相关不蕴含因果	27
8.2	线性相关与决定系数 R^2	27
8.3	单变量线性回归	27
8.4	双变量线性回归	28
8.5	多变量线性回归	28
附录 A	各分布的概率临界值表	31
A.1	t 分布	31
A.2	χ^2 分布	32
A.3	F 分布	33

第 1 章 写在前面

本知识手册记录了一些容易被忽视的统计基础概念，这也是为什么取名为“Statistic Beans: 统计学豆知識”。如果您在阅读时遇到了困难，欢迎联系作者。

作者的联系方式：

- 邮箱: zszs234@yeah.net
- Blog: <https://zesforu.pages.dev>
- GitHub: <https://github.com/Zes-Z>

1.1 本书内容

- 第 1 章，也就是你正在阅读的这里，会简要介绍 2-8 章的关键内容；
- 第 2 章，描述了什么是统计，统计到底在干什么？
- 第 3 章，一个完整的统计过程！
- 第 4 章，主要回答：如何将统计得到的一堆数字优雅地呈现出来？并最大效率地描述这堆数字表达的信息？
- 第 5 章，更进一步，我们需要一些概率和分布；
- 第 6 章，假设检验：从数字形式的统计量到文字描述！

如果我们假设今天喜家德没有喜三鲜，结果刚坐下点单时，发现隔壁桌吃的都是喜三鲜！

啊哈，看来我们的假设只有非常小的概率成立（因为可能有人外带了喜三鲜！）

所以，我们有很大把握今天喜家德有喜三鲜；

顺带一提，其实西芹鲜肉也不错！

- 第 7 章，方差分析，分析的是三个以上的组均值是否存在显著差异，差异的原因是什么；
- 第 8 章，给出多组一个或多个变量的对应数值，能否预测我们想知道的数据？
例如：给你最近十天的日照时间-平均气温的对应数据，你能根据今天的日照时间预测今天的平均气温吗？
不可以看天气预报！
- 第 9 章，
- 附录部分放置了一些常见分布的概率临界值表供参考

1.2 记录契机

这本“知识手册”，总结了一些学习概率论与数理统计的心得，足以覆盖初入统计涉及到的一些基础概念。其实在本学期开学前，作者本以为能从从容容地应付下述课程，结果却让我大为惊叹。此时距离《语言研究中的统计学》这门课结束还有半个月，距离托业考试还有一月余五天，最近无心学习，所以才有时间写这本小册子。第一次尝试写知识手册，不过请读者诸位放心，全文无杜撰，无毒，大可放心“食用”。

那么，为什么写这本小册子？答案很简单：为了方便。就如同日语中为了发音便利而产生了「音便」一般。如果把学习过的知识，总结记录下来，不论是对于再次查阅还是加深理解，都很有益。数周前，一位朋友和我探讨一些统计上的问题，大概是关于 F 分布和 p 值之类的，我本以为能够清晰简明地解释，但并非如此；几天前，和另一位朋友闲聊时，涉及到“统计学”时，不禁感叹道：“本来 ** 就没啥说服力，全靠吹气球”，如果不引用一点方法，那便真正陷入了循环论证。于是我再次翻开了参考书籍，萌发了将部分所学记录下来的念头。

此书写给自己和我的朋友们，如果有些许助益的话，也算是满足了我小小的幸福感。

1.3 阅读建议

以下是一些阅读本书的建议：

- 出现数学公式时，不会作过多的术语解说，只需要知道这串符号在**算些什么**，读者也可查阅相关资料。
- 本书会在术语首次出现时解释说明，后不再赘述，建议添加标签、笔记。
- 符号标记为分析案例，建议动手尝试，不要只看不做，那没有用。
- 由于作者水平、认知有限，特殊标记的内容仅为作者的见解，建议读者自查相关资料。
- 感到迷惑时立即停下，你需要补充相关知识，或者回头看看。基础不牢，地动山摇。
- 不想读时立即停下，你需要休息。

第2章 数据与统计量

2.1 数据一定是数字吗？

有人说，我们身处于一个物质世界。

但其实，我们也生活在一个数据世界之中... 我们的大脑，无时无刻都在处理海量的信息。每天早晨在睡意朦胧中，你听到闹钟响，然后爬起身来；洗漱时，你偶尔也会发呆，或回忆昨天发生的事情；打开手机和电脑，你快速地浏览消息并准备回复；工作时，你盯着满屏的文字、图片、excel 表格，感到两眼发花...

相信你已经感受到，**数据未必以数字的形式出现**。其实它也可以是文字、符号、甚至声音、图片、视频等，不过为了方便处理和研究，数据最终都会被转化为数字或类数字形式。

定义 2.1 (数据)

数据是对研究对象的某种属性或特征进行观测，测量或记录后得到的、能够用于描述和分析的信息。
数据是随机现象中观测结果的集合，是统计分析的基本材料。



2.2 统计量是什么？

获得足够量的数据以后，便有了进行统计研究的基础支撑。但是，我们不能简单地罗列出所有数据，这非常的不便，也没有意义，当然这也不能被称为**统计**。

因此，我们需要站在更高的总体的视角去提取样本数据 (集) 的信息，进行描述，分析；同时也应该以更加细致入微的视角，观察每个样本数据 (集) 之间的差异、联系。

定义 2.2 (统计量)

统计量是由样本数据计算得到的、且不包含未知总体参数的函数。
统计量 = 对样本数据进行某种计算得到的数值，用来描述样本或推断总体。



常见的统计量用于基础描述统计，主要有：

- **样本均值 $\bar{x}$** ：把所有数据加起来再除以个数，反映数据的“平均水平”或中心位置。例如，5 名同学的日语成绩分别是 60、70、80、90、100 分，则 $\bar{x} = (60 + 70 + 80 + 90 + 100)/5 = 80$ 分。
- **中位数**：把数据从小到大排列后位于正中间的数。它比均值更“扛得住”极端值。例如上面的成绩排序后中间是 80，中位数就是 80 分。
- **众数**：一组数据中出现次数（频数）最多的取值，代表“最常见的取值”。例如成绩 60、70、70、80、90 中，70 出现了两次、次数最多，所以众数是 70。一组数据可能没有众数，也可能有多个众数（如出现次数并列最多时）。
- **极差**：最大值减去最小值，是最简单的波动范围度量。例如最高分 100、最低分 60，极差就是 $100 - 60 = 40$ 分。它计算简单，但很容易被极端值带偏。
- **方差**：各数据与均值之差的平方的平均值，衡量数据整体偏离均值的程度。方差越大，说明数据越“散”。
- **标准差**：方差的算术平方根，和原始数据单位一致，所以比方差更直观。它衡量数据围绕均值的离散程度：标准差越大，数据越分散；标准差越小，数据越集中。例如成绩的标准差是 10 分，可以理解为“成绩围绕平均分波动的典型幅度约为 10 分”（对近似正态分布的数据，约 68% 落在均值 ± 1 个标准差之内）。
- **分位数**：把排序后的数据按位置切成若干等份。中位数就是第 50% 分位数（0.5 分位数）；第 25%、第 75% 分位数分别称为下四分位数和上四分位数，用来描述数据分布在哪些位置。
- **相关系数**：衡量两个变量之间线性相关的方向和强弱，取值范围在 $[-1, 1]$ 。越接近 1 表示正相关越强，越接近 -1 表示负相关越强，接近 0 表示几乎没有线性关系。

进阶的统计量用于从样本推断总体，主要有：

- **标准化统计量**：把数据减去均值再除以标准差，得到标准分（ z 分数）。它把不同尺度的数据放到同一把“尺子”上，方便比较。例如小明日语考 85 分、全班均值 80、标准差 5，则 $z = (85 - 80)/5 = 1$ ，说明他比平均高 1 个标准差。
- **偏度**：衡量分布左右不对称的程度和方向。偏度大于 0 说明右尾更长（右偏），小于 0 说明左尾更长（左偏），等于 0 说明大致对称。
- **峰度**：衡量分布是“尖”还是“平”，反映数据在均值附近集中的程度以及尾部的厚薄。峰度越大，分布通常越“尖”、尾部越厚。
- **t 统计量**：在总体方差未知、样本量较小时，用于检验均值是否等于某个值或两组均值是否有差异。它由“样本均值与假设值的差”除以“标准误差”得到，是 t 检验的核心。
- **F 统计量**：用于比较两个方差是否相等，或检验多个组的均值是否存在显著差异（方差分析）。它通常是两个方差之比，是 F 检验和方差分析的核心。
- **χ^2 统计量**：用于检验分类数据的“实际频数”与“理论频数”是否吻合，例如检验某枚骰子是否公平、两个分类变量是否独立。它把每个类别的“实际值减期望值”的平方除以期望值后加总得到。

2.3 统计 = 数据 + 统计量 + 统计推断

如果说数据是统计的原材料，统计量是从大量的数据中提取，精简信息，那么我们还需要一个统计推断，执行一个由样本推测总体的操作，才能完成一个完整的统计，统计推断也是统计学最核心的部分。

其中，数据回答：“我们观察到了什么？”统计量回答：“这些数据有什么特征？”统计推断回答：“这些特征是否具有说服力，能否推广到更大的范围？”

用一个例子把三者串起来：假设你了解全校学生的平均身高。

- **数据**：随机抽取 100 名学生，记录下每个人的身高，这 100 个数字就是数据。
- **统计量**：计算这 100 个身高的平均值 $\bar{x} = 168 \text{ cm}$ ，这就是从数据中提取出的统计量。
- **统计推断**：用样本均值 168 cm 去估计全校学生的平均身高，并判断这个估计有多可靠、误差有多大。

注 统计量是从样本中算出来的“已知数”，而总体的参数（如全校真实平均身高）是“未知数”。统计推断要做的事，就是借助统计量这个“已知数”，去合理地猜测那个“未知数”。

第3章 完整的统计过程

3.1 提出问题

通常情况下，我们希望量化研究或说明某个问题时，才会使用到统计。我们收集的数据，需要计算的统计量，以及统计推断和描述都将紧紧围绕最初的问题展开，这时，作为统计过程起点的问题提出就显得尤为重要。

但也有时，我们需要先抛出一个大致的猜想，根据已有可行的统计方法、预计能收集到的数据，来反向不断明确我们的问题。这样就不会出现：你提出了一个天马行空，富有研究意义的课题，却不知从何下手，用统计的手段来验证和解释你的课题的情况。

3.2 统计设计

拿到一个研究问题后，先别急着冲出去收集数据。统计设计就是在动手之前，把“要什么数据、从哪里来、怎么来、来了以后怎么办”统统想清楚。设计做得好，后面的路才走得顺；设计做得糙，很可能收集完数据才发现方法不对、样本没代表性，白忙一场。

统计设计至少要想清楚以下几件事：

- **研究问题与假设：**到底想回答什么？有没有一个可以检验的猜想？
- **总体与抽样对象：**我们的研究对象是谁？哪些人/物才算数？
- **抽样方法：**用概率抽样还是非概率抽样？怎么抽才能代表总体？
- **样本量：**大概需要多少条数据才够？太少了没说服力，太多了浪费。
- **变量与记录方式：**要记录哪些变量？怎么编码？用表格还是问卷？
- **统计检验的选择：**根据研究问题的类型判断该用哪种检验，并预判数据到手后会用哪些统计量。比如比较两组均值用 t 检验，比较多组均值用方差分析（ F 检验），考察分类变量是否独立用 χ^2 检验，考察两个变量的关系用相关或回归。

例如：假设你是一位日语教师，想了解学校里日语学生的日语考试成绩。统计设计阶段就应该想清楚：总体是“全校日语学生”，抽样采用分层抽样（按年级、班级各抽一部分），记录学号、年级、成绩等变量；由于研究问题是“平均分是否达标”，属于比较均值，所以计划用均值、标准差来描述，再用 t 检验来判断。这样到了采集数据时，每一步都有章可循。

注 统计设计不是一次性的“填空题”。随着对问题的理解加深，设计常常需要回头调整——比如发现某个变量不好收集，或样本量预算不够，那就及时修改方案，总比硬着头皮收一堆用不上的数据强。

3.3 样本数据采集——抽样方式与最佳组数

在完成统计设计后，即可开始统计研究的第一步实际操作——样本数据采集。

为了尽可能地保证统计的无偏差性和准确性，在采集样本数据时需要进行系统的、公平的、随机的抽样。既不能随心所欲地收集数据，也不能贪图方便省事。

例如：在上一个例子中，乍一看样本数据采集十分简单，只需收集一定量的日语成绩即可；但实际上这里藏了不少坑！首先你不能仅收集自己班级学生的信息作为样本数据集，数据的来源要尽可能的全面，多样，无偏好，最终保证你收集到的那一小部分数据能够很好地代表总体。所以你应该尽可能多的，随机收集学校里日语学生的日语考试成绩，再进行下一步的统计。

注 如果能收集到本学校所有日语学生的日语考试成绩自然是最好，这便是**总体**，但有时迫于现实原因或条件限制，我们只能收集到一部分数据，这便是用于**代表总体的样本**。只要你从总体中抽取样本的方式足够科学，那么即使只收集到一小部分数据，也能够很好地反应总体的情况。

以下是一些样本数据采集中使用到的经典抽样方法，前三种为概率抽样，后三种为非概率抽样：

- 简单随机抽样
- 系统抽样/等距抽样
- 分层抽样
- 便利抽样
- 判断抽样
- 滚雪球抽样

若采集到 N 条数据，现要分组，以直方图 (或其它) 形式分组展示，则应将其分为 k 组，总的样本数 N 与组数 k 满足斯特吉斯规则。

定理 3.1 (斯特吉斯规则 Sturges' rule)

$$k = 1 + \log_2 N$$



3.4 数据的整理与描述

初步采集的原始数据，往往是一堆乱糟糟的数字和记录，直接进行分析是不行的。**数据的整理与描述**，就是先把数据“收拾干净”，再用表格、图表和统计量把数据里的信息表现出来。

整理阶段通常要做这几件事：

- **检查与清洗**：看看有没有缺失值、重复记录、明显录错的数（比如成绩写成 150 分、身高写成 1.8 米却录成 18 米）。
- **编码与分类**：把文字信息转成可计算的类别或数字，例如把“男/女”编码成 0/1。
- **排序与分组**：把数据按大小排列；需要画直方图时，按第 3.3 节的斯特吉斯规则确定组数再分组。
- **制作频数表**：统计每个取值或每个组里有多少条数据，一眼看出分布的大致形状。
- **可视化**：用直方图、箱型图、条形图等把分布展示出来（详见第 4 章）。
- **计算描述统计量**：均值、中位数、众数、方差、标准差、分位数等，用数字概括数据特征。

例如：你收集到 50 名日语学生的成绩，先检查有没有缺考或录错的分数；再按 60 以下、60–70、70–80、80–90、90 以上分组做频数表；接着画一张直方图看看成绩大致集中在哪一段；最后算出平均分、标准差，心里就有数了。

注 整理和描述不是“为了好看而折腾”。同一个数据集，分组方式、图表类型选得不一样，给人留下的印象可能完全不同。整理阶段多花点心思，能避免后面被数据“误导”。

3.5 计算与分析数据

数据整理好以后，就到了真正“算”和“想”的环节。**计算与分析数据**，不只是把统计量按公式计算出来，更重要的是**结合研究问题去解读这些数字**：它们说明了什么？能不能支撑我们的猜想？

这一步通常按这样的思路走：

- **选对统计量**：根据数据类型和研究问题，选择合适的手段。比如比较平均水平用均值或中位数，看离散程度用标准差，看两个变量的关系用相关系数。
- **计算描述统计量**：先用均值、中位数、标准差、分位数等把数据的“长相”描述出来。
- **进行统计推断**：如果需要由样本推测总体，就做点估计、区间估计或假设检验（如 t 检验、 F 检验、 χ^2 检验）。
- **回到问题本身**：把计算结果放回最初的研究问题里，用自然语言下结论，而不是扔一堆数字让读者自己猜。

例如：你算出 50 名日语学生的平均分是 82 分、标准差是 8 分。光说“平均 82 分”还不够，你还想知道这个样本能否代表全校——于是做一次 t 检验，判断全校日语学生的平均分是否显著高于 80 分，再根据 p 值给出结论。

注 计算只是手段，不是终点。拿到一个“显著”的结果，也别急着欢呼：还要想想样本有没有代表性、效应在实际中够不够大、有没有其他解释。统计显著不等于实际重要，更不等于因果关系。

3.6 完整的统计步骤

把前面几节串起来，一次完整的统计大致会经历下面几步。值得注意的是，这条路并不是只能走一遍：当分析结果不理想、发现设计有漏洞时，常常需要回到前面的步骤重新调整。




图 3.1: 完整的统计步骤流程图

注 流程图里最容易被忽略的是那条“回头”的箭头。现实中很少有统计能一次走通：数据收得不够、分析结果不显著、问题本身要修正，都是常有的事。允许回头，才是完整的统计过程。

第 4 章 数据的可视化与描述

4.1 使用图展示数据

在前面的章节做了必要的准备后，本章开始介绍。数据整理好以后，一张合适的图往往比一大段文字更能让人一眼看出规律。本章先用**二维图**入门，再逐步介绍三维图和降维显示。

4.1.1 二维图

二维图是在一张平面图上，用横轴和纵轴承载信息，最常见的有直方图、折线图、箱型图和散点图。

4.1.1.1 直方图

直方图用来展示**一组数值数据的分布**：把数据按区间分组，每个区间画一根柱子，柱子的高度表示落在该区间的数据个数（频数）。

例如，某次日语测验 40 名学生的成绩如下（单位：分）：

56, 58, 61, 63, 65, 67, 68, 70, 71, 72,
73, 74, 75, 75, 76, 77, 78, 78, 79, 80,
80, 81, 82, 83, 84, 85, 85, 86, 87, 88,
89, 90, 91, 92, 93, 95, 96, 97, 98, 100

按每 10 分一组，可以得到下面的频数表：

表 4.1: 40 名学生的日语成绩频数表

成绩区间（分）	人数
50-59	2
60-69	5
70-79	12
80-89	12
90-100	9




图 4.1: 40 名学生日语成绩直方图

从直方图可以直观看到：成绩大多集中在 70–89 分，两头少、中间多，整体分布比较接近“中间高、两边低”的形状。

4.1.1.2 折线图

折线图适合展示数据随时间或其他有序变量的变化趋势。横轴通常是有先后顺序的类别（如星期、月份），纵轴是数值。

例如，某位同学连续一周每天复习日语的时间（单位：分钟）如下：

周一 30，周二 45，周三 40，周四 60，周五 50，周六 90，周日 80




图 4.2: 一周每天复习日语时间折线图

从折线图可以清楚看到：周中起伏不大，但到了周末复习时间明显上升——这就是折线图“看趋势”的用处。

4.1.1.3 箱型图

箱型图用来概括一组数据的分布位置和离散程度，它能同时显示最小值、下四分位数、中位数、上四分位数和最大值，还能把异常值“暴露”出来。

例如，比较三个班的日语成绩（每班 10 人）：

1 班：60, 65, 70, 72, 75, 78, 80, 82, 85, 90

2 班：55, 60, 62, 68, 70, 72, 75, 78, 80, 85

3 班：70, 75, 78, 82, 85, 88, 90, 92, 95, 98




图 4.3: 三个班日语成绩箱型图

一眼看去，3班的箱子整体位置最高，说明成绩整体最好；2班的箱子最“胖”，说明成绩比较分散。

4.1.1.4 散点图

散点图用来观察两个数值变量之间是否有关系，每个点代表一条数据。

例如，10名同学每天学习日语的时间与日语成绩如下：

学习时间（小时）：2, 3, 4, 5, 6, 7, 8, 9, 10, 11

日语成绩（分）：58, 62, 68, 66, 75, 80, 83, 96, 92, 95




图 4.4: 学习与日语成绩散点图

这些点大致从左下往右上排列，说明学习时间越长、成绩越高，两者呈现正相关——更严格的度量方法（相关系数）会在后面章节介绍。

注 二维图虽然简单，但选错图很容易误导读者：想看分布用直方图，想看趋势用折线图，想比分布位置用箱型图，想看两个变量的关系用散点图。先想清楚要回答什么问题，再选图进行展示。

4.1.2 三维图

二维图只能同时看两个变量，当我们想观察三个变量的关系时，就可以把图“立起来”，变成三维图。三维图最常见的形式是三维曲面图和三维散点图，其中**三维曲面图**特别适合展示“一个数值随两个变量连续变化”的情况。

例如，二元正态分布的密度曲面就像一个“山包”：中心最高，向四周平滑地下降。这张图用 $z = e^{-(x^2+y^2)/2}$ 示意，横轴和纵轴是两个变量，竖轴是密度值。




图 4.5: 二元正态密度曲面示意图

三维曲面图能让人一眼看到“整体形状”，比如哪里高、哪里低、怎么过渡。但它也有代价：在纸面上不容易精确读数，人眼也容易看花。所以实际分析中，三维图多用来“找感觉”，精确判断还是要靠统计量。

4.1.3 高维度的降维显示

变量一旦超过三个，二维、三维图都画不下了。这时常用的思路是**降维**：把高维数据投影到二维或三维空间，同时尽量保留数据原有的差异和结构。

常见的降维方法有：

- **主成分分析 (PCA)**：找几个新的、互不相关的“综合变量”，用它们代表原来的众多变量。
- **t-SNE**：擅长把高维数据“摊开”到二维，让相似的样本在图上靠得更近，常用于可视化聚类结果。
- **UMAP**：类似 t-SNE，但速度更快、对全局结构保留得更好。

注 降维后的图只是“投影”，不是原始数据的完整还原。它适合用来发现大致的模式（比如哪些样本聚在一起），但下结论之前，还是要回到原始变量上验证。**降维是辅助眼睛，不是替代统计。**

4.2 使用统计量描述数据

图能让人“看见”数据，但写报告、做比较时，还是需要数字来精确地描述。这一节把第 2 章提到的统计量正式用起来，分成“常用统计量”和“各个分布的统计量”两部分。

4.2.1 常用统计量

常用统计量大致可以分成三类：描述**集中趋势**、描述**离散程度**、描述**分布位置与形状**。

1. 集中趋势：数据“集中在哪”

- 样本均值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$: 所有数据的算术平均, 最常用, 但容易被极端值拉偏。
 - 中位数: 排序后正中间的数, 极端值再多也“不为所动”。
 - 众数: 出现次数最多的取值, 适合描述分类数据或“最常见的水平”。
2. 离散程度: 数据“散不散”
- 极差 $R = x_{(n)} - x_{(1)}$: 最大值减最小值, 简单, 但只看了两个极端值。
 - 样本方差 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$: 数据偏离均值的平均平方程度。
 - 样本标准差 $s = \sqrt{s^2}$: 和原始数据同单位, 比方差更直观。
 - 变异系数 $CV = \frac{s}{\bar{x}}$: 去掉单位的影响, 用来比较尺度不同的数据谁更“散”。
3. 分布位置与形状
- 分位数: 如第 25%、50%、75% 分位数 (下四分位数、中位数、上四分位数), 描述数据分布在哪些位置。
 - 偏度: 分布是否左右对称、偏向哪边。
 - 峰度: 分布是“尖”还是“平”、尾部厚不厚。
- 用回 4.1.1 那 40 名学生的日语成绩, 可以算出下面这些常用统计量:

表 4.2: 40 名学生成绩的常用统计量

统计量	数值	统计量	数值
均值 $\bar{x}$	79.95	极差 R	44
中位数	80	样本方差 s^2	128.20
下四分位数	72.5	样本标准差 s	11.32
上四分位数	88.5	变异系数 CV	0.14

注 这份数据里, 均值 79.95 和中位数 80 非常接近, 说明成绩分布比较对称, 没有明显的极端值捣乱; 标准差约 11.32 分, 大致可以理解为“大部分学生的成绩在平均分上下 10 分出头浮动”。只看均值不看离散程度, 很容易被“平均”骗了。

4.2.2 各个分布的统计量

不同的概率分布都有自己固定的期望 (均值) 和方差。记住这些结论, 后面做参数估计和假设检验时能省很多事。

表 4.3: 常见分布的期望与方差

分布	记号	期望 $E(X)$	方差 $Var(X)$
0-1 分布	$B(1, p)$	p	$p(1 - p)$
二项分布	$B(n, p)$	np	$np(1 - p)$
泊松分布	$P(\lambda)$	λ	λ
均匀分布	$U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态分布	$N(\mu, \sigma^2)$	μ	σ^2
指数分布	$Exp(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
t 分布	$t(k)$	$0 \ (k > 1)$	$\frac{k}{k-2} \ (k > 2)$
χ^2 分布	$\chi^2(k)$	k	$2k$
F 分布	$F(k_1, k_2)$	$\frac{k_2}{k_2-2} \ (k_2 > 2)$	$\frac{2k_2^2(k_1+k_2-2)}{k_1(k_2-2)^2(k_2-4)} \ (k_2 > 4)$

注 几个容易记的小规律: 泊松分布“期望等于方差”; 正态分布完全由 μ 和 σ^2 两个参数决定; t 、 χ^2 、 F 这几个用于检验的分布, 其期望和方差往往只在自由度足够大时才存在或才简洁。

第5章 概率与分布

5.1 概率为 0 就是不可能事件吗？

直觉上，概率是 0 的事情好像就“绝不会发生”。但在统计学里，这个直觉要小心：**概率为 0 并不等于不可能发生，概率为 1 也不等于必然发生。**

关键在于区分**离散型**和**连续型**随机变量：

- **离散型**：取值是一个个孤立的点，概率 0 通常就意味着“这件事不发生”。
- **连续型**：取值是某个区间里的任意实数，任何一个“单点”的概率都是 0。例如 $X \sim U(0, 1)$, $P(X = 0.5) = 0$ ，但 0.5 并不是不可能出现——只是它太“细”了，单独一个点没有“长度”，所以概率算出来是 0。

注 可以这样理解：在数轴上随机撒一个点，它正好落在 0.5 这个“没有宽度”的位置上，概率当然是 0；但这并不意味着 0.5 不存在。所以连续分布里，“概率为 0 的事件”和“不可能事件”是两回事。

5.2 什么是分布？

“分布”这个词，本质上是在回答一个问题：**一个随机变量取各种可能值的概率，是怎么“摊开”的。**

例如掷一颗公平的骰子：

- 可能取值是 1、2、3、4、5、6；
- 每个点数出现的概率都是 $\frac{1}{6}$ 。

把“每个取值对应多少概率”完整画出来，就是下面这张柱状图：




图 5.1: 公平骰子的概率分布（离散均匀分布）

这种取值是孤立点、每个点都有明确概率的，叫**离散型分布**。注意，所有柱子的高度加起来正好等于 1。

但现实中的骰子不一定是公平的。假如这颗骰子被动了手脚，1 点和 2 点更容易出现：

- $P(1) = \frac{1}{4}$, $P(2) = \frac{1}{4}$, $P(3) = \frac{3}{20}$, $P(4) = \frac{3}{20}$, $P(5) = \frac{1}{10}$, $P(6) = \frac{1}{10}$

画出来就是这样一张“高低不平”的图：




图 5.2: 被动手脚后的骰子概率分布（不均匀分布）

同样是 1–6 的取值，概率怎么分配不一样，分布就不一样——这就是“分布”的意义。

所以一句话总结：**分布 = 把所有可能取值，以及它们“被抽中的可能性”，完整地描述出来。**

注 分布就像是数据的“户口本”：它告诉我们数据可能长什么样、哪些值常见、哪些值罕见。后面要讲的标准正态分布、二项分布、泊松分布等，都是具有某种特定“长相”的分布。

5.3 标准正态分布

在讲标准正态分布之前，我们先要知道**连续型分布**是怎么回事。与**取值**是孤立点、每个点都有明确概率的**离散型分布**不同，我们有时会遇见**连续**的数据，这里的连续不是排队那种位置上的前后连续，而是分布中，**数值取值**的连续，比如我们现在有一个无数个面的概念骰子，它能摇出 1 点，还能摇出 1.999 点，甚至是 1.0000...1 至 6 点之间所有的数。像这样取值是连续的，可以无限接近的数据的分布，就是连续型分布。正态分布是统计里最重要的连续型分布之一，而**标准正态分布**是其中最“标准”的一款：均值 $\mu = 0$ 、方差 $\sigma^2 = 1$ ，记作 $N(0, 1)$ 。它的概率密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

标准正态分布曲线长得像一个左右对称的“钟”：曲线下方的面积之和，即总概率“1”




图 5.3: 标准正态分布密度曲线

例如, 假设某校学生的身高近似服从正态分布, 均值 173 cm、标准差 5 cm。它的密度曲线仍然是一个“钟”, 但对称轴从 0 挪到了 173 cm:




图 5.4: 以身高为例的正态分布曲线 (对称轴 173 cm)

分布曲线关于 173 cm 完全对称, 越靠近 173 cm 密度越高, 越往两边越低。这表示这个学校绝大多数学生的身高都“中规中矩”, 在 173cm, 长得特别高的人数 (或概率) 比较小, 同样的, 长得特别矮的人数 (或概率) 也比较小。换句话说, 一组符合正态分布的数据, 绝大部分都中规中矩, 越是极端的数据, 出现概率越小。

标准正态分布有几个常用性质:

- 关于 $x = 0$ 完全对称, 均值、中位数、众数都等于 0。
- 曲线下的总面积等于 1, 也就是所有可能取值的概率总和为 1。
- **68-95-99.7 法则**: 约 68% 的数据落在正负一个标准差内, 约 95% 落在正负两个标准差内, 约 99.7% 落在正负三个标准差内。

注 任何正态分布 $N(\mu, \sigma^2)$ 都可以通过标准化

$$Z = \frac{X - \mu}{\sigma}$$

变成标准正态分布 $N(0, 1)$ 。所以查概率表时, 只需要一张标准正态分布表就够了。这也是标准正态分布如此“标准”的原因。

5.4 离散型随机变量及其分布

离散型随机变量的取值是一个接一个的孤立点, 每个取值都有明确的概率, 所有取值的概率加起来等于 1。前面 5.2 里掷骰子就是典型的离散型分布。下面介绍三个最常用的离散分布: 0-1 分布、二项分布、泊松分布。

5.4.1 0-1 分布

0-1 分布是最简单的离散分布, 随机变量只取两个值: 0 和 1。通常把“成功”记为 1、“失败”记为 0, 成功概率为 p :

$$P(X = 1) = p, \quad P(X = 0) = 1 - p$$

例如, 抛一次硬币, 正面朝上记为 1、反面记为 0, 就服从 0-1 分布; 一次考试及格记为 1、不及格记为 0, 也服从 0-1 分布。

0-1 分布的期望和方差都很简洁:

- 期望: $E(X) = p$
- 方差: $Var(X) = p(1 - p)$

5.4.2 二项分布

把 0-1 试验独立地重复 n 次，记录“成功”的总次数 X ， X 就服从二项分布，记作 $X \sim B(n, p)$ 。它刻画的是：在 n 次独立重复试验中恰好成功 k 次的概率

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

例如，连续抛 10 次硬币，正面朝上的次数 $X \sim B(10, 0.5)$ 。正面出现 0 次、5 次、10 次的概率各不相同，画出来就是下面这张柱状图：




图 5.5: 二项分布 $B(10, 0.5)$ 的概率分布

二项分布的期望和方差：

- 期望： $E(X) = np$
- 方差： $Var(X) = np(1-p)$


注 0-1 分布其实就是 $n = 1$ 时的二项分布。二项分布适合“次数有限、每次成功概率固定”的独立重复试验。

5.4.3 泊松分布

泊松分布用来描述单位时间、单位面积或单位长度内“稀有事件”发生次数的分布，记作 $X \sim P(\lambda)$ ，其中 λ 是平均发生次数：

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

例如，一小时内到达某商店的顾客数、一页书上印刷错误的数量、某路段一小时内发生的交通事故数，都常用泊松分布描述。以 $\lambda = 3$ 为例，画出来就是下面这张柱状图：

图 5.6: 泊松分布 $P(3)$ 的概率分布

泊松分布最显眼的特征是：

- 期望： $E(X) = \lambda$
- 方差： $Var(X) = \lambda$

期望等于方差，是泊松分布的“招牌”。

注 当二项分布的 n 很大、 p 很小时，二项分布可以近似看成泊松分布（此时 $\lambda = np$ ）。所以泊松分布也常用来近似“大量试验中成功次数很少”的情形。

5.5 自由度

自由度（degrees of freedom，简写 df）是一个听起来很高大上，其实很朴素的概念。不妨先来思考一个小问题：

如果已知一个 6 人小组的平均成绩，那么至少需要知道几个人的成绩，才能准确说出每个人的成绩？

答案是 5 个。因为在知道前 5 个人的成绩之前，最后一个人的成绩都是“未知”的；可一旦前 5 个人的成绩都知道了，最后一个人的成绩就被“锁死”了——它必须负责“兜底”，保证平均分对得上，这样才能“万事大吉”。

也就是说，这 6 个人里，真正能自由变化的只有前 $n - 1 = 5$ 个人，剩下的 1 个人是“工具人”，专门用来保证平均值成立。这里的 $n - 1$ （样本量减 1）就是**自由度**，记作 df。

推广到一般情况：

- **自由度 = 数据个数 - 不得不“牺牲”掉的约束个数；**
- 每估计一个参数（比如均值），通常就要少掉一个自由度。

这也是为什么样本方差

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

要用 $n - 1$ 做分母，而不是 n ：因为均值 $\bar{x}$ 已经被估计出来了，数据不再完全自由。

常见分布里的自由度：

- $\chi^2(k)$ 分布有 k 个自由度；
- $t(k)$ 分布的自由度为 k ；
- $F(k_1, k_2)$ 分布有两个自由度：分子自由度和分母自由度；
- 卡方独立性检验中， $r \times c$ 列联表的自由度为 $(r - 1)(c - 1)$ 。

注 自由度不是玄学，它决定了 t 、 χ^2 、 F 这些分布的“长相”。样本量越小、约束越多，自由度就越小，分布也就越“胖”、越不自信；样本量越大，自由度越大，这些分布会越来越接近正态分布。

第 6 章 假设检验：从统计量到结论

6.1 假设检验与 p 值解读

先来想一个有点“抬杠”的问题：如何证明“并非世界上所有的人都是女人”？

直接证明它很麻烦，但**证伪**就容易多了——只需找到一个反例：一个男人。于是我们先把“世界上所有的人都是女人”当作一个待检验的假设（原假设 H_0 ），然后努力找反例；只要找到一个男人，就有充分理由推翻 H_0 ，从而接受“并非所有人都是女人”这个结论。

假设检验就是这个思路：先假设一个“无事发生”的立场，再拿数据看能不能把它推翻。

一套完整的假设检验通常按下面几步走：

1. **提出假设**：原假设 H_0 （通常是“没有差异/没有关系/没有效果”），备择假设 H_1 （通常是“有差异/有关系/有效果”）。
2. **选择合适的检验**：根据数据类型和问题选 t 检验、 χ^2 检验、 F 检验等。
3. **计算检验统计量和 p 值**： p 值表示“在 H_0 为真的前提下，出现当前样本结果（或更极端结果）的概率”。
4. **比较显著性水平**：临界（概率）值通常取 $\alpha = 0.05$ 。若 $p < \alpha$ ，说明在 H_0 成立时还能看到这么极端的结果概率很小，于是有理由拒绝 H_0 。
5. **下结论**：如果计算出来 p 值小于临界值，则拒绝 H_0 ，支持 H_1 ；若 p 值高于临界值，不能直接接受 H_0 只能说“证据不足”，不能说明原假设 H_0 一定正确。

举个例子：某张期末成绩表里，乍一看男同学的体育成绩比女同学平均高 5 分，现在想探究男女体育成绩是否真的存在差异。我们需要给出假设：

- H_0 ：体育成绩与性别无关（差异只是巧合）；
- H_1 ：体育成绩与性别有关（存在真实差异）。

用统计软件或者手算在 H_0 前提下，得到现有成绩表的概率 p 值：

- 若 $p < 0.05$ ：说明在“无关”的假设下，出现“男比女平均高 5 分”这种结果的可能性不到 5%，我们更有理由相信这不是巧合，于是拒绝 H_0 ，认为体育成绩与性别存在差异。
- 若 $p = 0.33$ ：说明在“无关”的假设下，出现这种结果的概率高达 33%，这说明一切很可能只是巧合，于是不能拒绝 H_0 。

注 p 值小，说明“如果 H_0 是真的，那这次样本结果太离谱了”，所以我们倾向于不相信 H_0 。但要注意： p 值大不代表 H_0 正确，只代表“证据不足以拒绝它”。另外， $p < 0.05$ 也不等于“实际效果很大”，更不等于因果关系。

6.2 置信区间

用样本估计总体参数，最朴素的办法是给一个“点”：比如抽 100 个学生，算出平均身高 168 cm，就猜全校平均身高是 168 cm。但这样做太“自信”了——换一批样本，结果可能就不是 168 了。

更稳妥的做法是给一个**区间**：例如“有 95% 的把握，全校平均身高在 166.2 cm 到 169.8 cm 之间”。这个区间就叫**置信区间**，95% 叫**置信水平**。

定义 6.1 (置信区间)

设总体参数为 θ ，由样本构造区间 $(\hat{\theta}_L, \hat{\theta}_U)$ 。若该区间以 $1 - \alpha$ 的概率包含 θ ，则称它为 θ 的置信水平为 $1 - \alpha$ 的置信区间。

常用的形式是“点估计 $\pm$ 误差范围”：

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \quad (\text{总体方差已知时}) \quad \bar{x} \pm t_{\alpha/2}(n-1) \cdot \frac{s}{\sqrt{n}} \quad (\text{总体方差未知时})$$

怎么理解“95%”？

- 不是“总体均值有 95% 的概率落在这个区间里”（总体参数是固定值，不是随机变量）；
 - 而是：如果重复抽样很多次，每次都构造一个 95% 置信区间，那么大约有 95% 的区间会包含总体均值。
- 例如：抽 100 名学生，样本均值 168 cm，标准差 8 cm，则 95% 置信区间约为

$$168 \pm 1.96 \times \frac{8}{\sqrt{100}} = 168 \pm 1.568 = (166.43, 169.57)$$

可以写成：全校学生平均身高的 95% 置信区间为 (166.43, 169.57) cm。

注 置信区间比单个点估计更有信息量：区间越窄，说明估计越精确；区间越宽，说明不确定性越大。它和假设检验其实是一体两面——若某个假设值不在置信区间内，通常对应的检验也会拒绝 H_0 。

6.3 t 检验：关注“平均值”的差异

t 检验用来回答“平均值有没有差异”的问题，常见有三种：

- **单样本 t 检验**：检验一个样本的均值是否等于某个已知值。例如：50 名日语学生的平均分是否显著高于 80 分。
- **独立样本 t 检验**：比较两个独立组的均值。例如：男、女生的体育成绩是否有差异。
- **配对样本 t 检验**：比较同一批对象前后两次测量。例如：同一批学生培训前后的日语成绩是否有提高。

单样本 t 检验的统计量为

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

其中 $\bar{x}$ 是样本均值， μ_0 是假设的总体均值， s 是样本标准差， n 是样本量， t 服从自由度为 $n-1$ 的 t 分布。

例如：50 名学生日语成绩均值 82 分、标准差 8 分，想检验是否显著高于 80 分：

- $H_0: \mu = 80, H_1: \mu > 80$;
- $t = \frac{82 - 80}{8/\sqrt{50}} \approx 1.77$;
- 查 t 分布表 (df=49) 得 p 值，若 $p < 0.05$ 则拒绝 H_0 。

注 t 检验适合小样本，且要求数据近似正态、两组方差不要差太多。样本量很大时， t 分布会越来越接近标准正态分布，检验结果也会越来越“稳”。

6.4 χ^2 (卡方) 检验：关注“数量/频率”的分布

χ^2 检验（卡方检验）用于分类数据，关心的是“实际频数”和“理论频数”是否吻合。常见两种用途：

- **拟合优度检验**：检验一组分类数据的分布是否符合某个理论分布。例如：一枚骰子是否公平。
- **独立性检验**：检验两个分类变量是否相互独立。例如：性别与是否选修日语课是否有关。

χ^2 统计量的基本形式：

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

其中 O 是实际观测频数， E 是理论期望频数。 O 和 E 差得越多， χ^2 越大，越说明“不符合/不独立”。

例如检验一枚骰子是否公平：掷 60 次，理论上每个点数应出现 10 次；若 1 点出现 20 次、6 点出现 2 次， O 和 E 差很多， χ^2 就会很大， p 值很小，从而怀疑骰子被动了手脚。

独立性检验的自由度：

$$df = (r - 1)(c - 1)$$

其中 r 是行数， c 是列数。

注 χ^2 检验用的是“频数/次数”，不是“均值”。所以它和 t 检验的分工很清楚：比较平均值用 t 检验，比较数量/频率的分布用 χ^2 检验。

6.5 非技术用语的假设检验总结模板

本节提供一个假设检验结果书写模板，便于简要地呈现假设检验过程与结论。使用时只需替换方括号中的内容。

本研究旨在探讨 [研究目的]。据此提出如下假设：

零假设 (H_0): [没有差异/没有关系/没有效果]。**备择假设 (H_1):** [存在差异/存在关系/存在效果]。

为检验上述假设，采用 [检验方法，如独立样本 t 检验、 χ^2 独立性检验、单因素方差分析等]。检验的显著性水平设为 $\alpha = 0.05$ 。

分析结果显示，检验统计量为 [统计量值]，自由度为 [自由度]，查表 (或软件自动计算) 知，对应的 p 值为 [p 值]。

由于 p 值 [$</>$] 显著性水平 $\alpha = 0.05$ ，[拒绝/不能拒绝] 零假设 H_0 。据此可以认为，[根据 H_1 表述研究结论，如：样本数据提供了统计学上显著的证据，表明……；或：样本数据未提供足够的证据表明……]。

综上所述，[用一句话概括研究结论，但不作因果推断]。

注 正式书写时有几点需要注意：

- p 值应给出具体数值或明确的比较关系（如 $p < 0.05$ 、 $p = 0.032$ ），不宜只写“显著/不显著”；
- “拒绝 H_0 ”只能说“差异（或关系）具有统计学意义”，不能直接说“具有实际意义”或“存在因果关系”；
- 若不能拒绝 H_0 ，应表述为“没有充分的证据拒绝 H_0 ”，而不是“ H_0 成立”；
- 报告时应同时给出检验方法、统计量、自由度和 p 值，保证结果可复核。

第7章 方差分析

7.1 前置知识-方差分析在“分析”什么

t 检验适合比较两个组的均值。那如果现在有四个班、两种教学方法、三种教材，要比较学生成绩的平均值呢？

一个天真的想法是两两做 t 检验：4 个班之间要比较 6 次，3 种教材之间要比较 3 次。但比较次数一多，犯“假阳性”错误（本来没差异却说有差异）的概率就会悄悄变大，这叫做**多重比较问题**。

方差分析（ANOVA）就是为了解决这个问题而生的：它**一次性比较多个组的均值是否相等**，而不是两两乱比。

那么方差分析到底在“分析”什么？名字里有“方差”，但它关心的其实是**均值**。它的思路是把数据的总差异拆成两部分：

- **组间差异**：各组均值之间的差异，反映“不同组是否真的不一样”；
- **组内差异**：同一组内部个体之间的差异，反映“随机波动有多大”。

如果组间差异相对组内差异足够大，说明“分组”确实起了作用，各组均值不像是一家人。这个“够不够大”用 F 统计量来衡量：

$$F = \frac{\text{组间均方}}{\text{组内均方}}$$

F 越大，对应 p 值越小，越有理由认为各组均值存在显著差异。

注 方差分析有几个基本前提：各组数据近似正态、各组方差大致相等（方差齐性）、各组观测相互独立。前提满足得越好，结果越可靠。

7.2 单因素方差分析

单因素方差分析只考察一个因素，比较这个因素的多个水平（组）之间均值是否有差异。

例如：想比较三种日语教材的教学效果，首先随机把学生分成 3 组，每组用不同教材学习一学期，最后比较三组的平均成绩。（如果学生已经按照不同教材学习了一学期，则直接收集数据即可，不用从零开始）

- H_0 ：三组平均成绩相等（即三种教材的教学效果没有差异）；
- H_1 ：至少有一组的平均成绩与其他组不同（即至少一种教材的教学效果与其他教材有差异）。

方差分析的结果通常整理成下面这样一张方差分析表，也可由统计软件自动得出：

表 7.1: 单因素方差分析表

变异来源	平方和	自由度	均方	F
组间	SS_B	$k - 1$	$MS_B = \frac{SS_B}{k-1}$	$\frac{MS_B}{MS_W}$
组内	SS_W	$n - k$	$MS_W = \frac{SS_W}{n-k}$	
总计	SS_T	$n - 1$		

其中 k 是组数， n 是总样本量。软件会算出对应的 p 值：若 $p < 0.05$ ，拒绝 H_0 ，认为至少有一组均值不同。

注 方差分析只能告诉你“有没有差异”，不能告诉你“具体哪两组有差异”。想知道哪两组不同，还要再做**事后检验**（多重比较），比如 Tukey 检验。

7.3 双因素方差分析

双因素方差分析同时考察两个因素对结果的影响，不仅可以检验每个因素的主效应，还能检验两个因素之间是否存在交互效应。

例如：研究“教学法”（因素 A，3 种）和“性别”（因素 B，2 种）对日语成绩的影响，可以得到 $3 \times 2 = 6$ 个组合。双因素方差分析会分别检验：

- 因素 A 的主效应：不同教学法之间成绩是否有差异；
- 因素 B 的主效应：男女之间成绩是否有差异；
- 交互效应：教学法的效果是否“看人下菜”，比如某种教学法对女生特别有效、对男生却一般。

交互效应是双因素方差分析最值得关注的地方：如果两个因素之间存在交互作用，就不能只单独看某一个因素的“平均效果”，因为一个因素的效果可能依赖于另一个因素的水平。

注 画一张“交互图”很有帮助：横轴放一个因素，不同折线代表另一个因素的不同水平。若折线明显交叉或分岔，往往意味着存在交互效应。

7.4 多因素方差分析

多因素方差分析把双因素推广到三个或更多因素，原理完全一样：检验每个因素的主效应，以及因素之间的各种交互效应。

例如：研究“教学法 $\times$ 性别 $\times$ 课时长度”三个因素对日语成绩的影响，就是一个三因素方差分析。

因素一多，事情会变得复杂：

- 交互项的数量迅速增加（两两交互、三阶交互……）；
- 需要的样本量更大，否则很多组合“没人”；
- 结果解释也更烧脑：高阶交互往往很难用一句话讲清楚。

实际研究中，多因素方差分析通常交给统计软件完成，分析思路和单因素、双因素一脉相承：**先看交互，再看主效应，最后回到实际问题下结论。**

注 因素越多不等于越高级。如果样本量不够或交互项解释不清，强行塞很多因素反而会让结论变得不可靠。好的设计是“够用就好”，不是“越多越好”。

第 8 章 线性回归

8.1 相关不蕴含因果

什么是相关性？什么是因果？如果“只要 A 发生，B 就发生”，那 A 和 B 就是因果关系；而相关只表示二者存在某种关联，至于关联有多强、是谁引起谁、有没有第三者在背后捣乱，都还说不准。

举个经典例子：入冬后，某商场短款羽绒服的销量逐渐上升，与此同时，同地区医院的骨折人数也在增加。把两条折线画在一起，趋势几乎同步，相关系数可能还挺高。难道卖羽绒服会导致骨折吗？这显然很荒谬。

其实真正的原因是**天气变冷**：气温越低，羽绒服卖得越好；同时路面结冰，摔骨折的人也变多。羽绒服销量和骨折人数只是“碰巧一起变”，它们之间并没有因果关系。

所以做统计时要时刻记住三件事：

- **相关不意味着因果**：就算两个变量相关到“离谱”，也不能直接说一个导致另一个。
- **小心伪相关**：冰淇淋销量和溺亡人数、医院数量和奢侈品消费量，这类“纸面上相关、实际上无关”的例子很多，背后往往藏着被忽略的第三因素（比如气温、经济发展水平）。
- **不要预设结论**：带着“我想要的结果”去分析，容易只看到支持自己的证据。应该从一个公正的问题出发，用数据说话。

注 相关只能告诉你“它们总是一起变”，因果则需要实验设计、控制变量等更严格的手段才能判断。统计上显著的相关，离“因果”还差得远。

8.2 线性相关与决定系数 R^2

当两个数值变量大致呈直线关系时，我们用**相关系数** r 来度量线性相关的方向和强弱：

$$r \in [-1, 1]$$

- $r > 0$ ：正相关，一个变大另一个也变大；
- $r < 0$ ：负相关，一个变大另一个变小；
- $|r|$ 越接近 1，线性关系越强；越接近 0，线性关系越弱。

光看 r 还不够，我们常常更关心： x 的变化能解释 y 的多少变化？这就用到**决定系数**：

$$R^2 = r^2$$

R^2 的取值范围是 $[0, 1]$ ，它表示因变量 y 的变异中有多大比例能被自变量 x 的线性关系解释。

例如， $r = 0.8$ 时， $R^2 = 0.64$ ，意思是“学习时间”这个变量大约能解释“成绩”变异的 64%，剩下 36% 来自其他因素或随机波动。

注 R^2 高说明线性拟合得好，但不说明 x 就是 y 的原因。哪怕 $R^2 = 0.99$ ，也可能只是伪相关。相关和回归描述的是“关系”，不是“因果”。

8.3 单变量线性回归

单变量线性回归（也叫一元线性回归）用一个自变量 x 去预测因变量 y ，模型写成：

$$y = a + bx + \varepsilon$$

其中 a 是截距， b 是斜率， ε 是随机误差。拟合出来的一条直线叫**回归线**：

$$\hat{y} = a + bx$$

回归线怎么找？最常用的方法是**最小二乘法**：让所有样本点到回归线的竖直距离（残差）的平方和最小。
例如，用“每天学习时间”预测“日语成绩”，10 名同学的数据可以拟合成

$$\hat{y} = 50.25 + 4.15x$$

意思是：学习时间每增加 1 小时，成绩平均提高约 4.15 分；学习 0 小时时，成绩的“基准”约为 50.25 分。




图 8.1: 学习与日语成绩的散点图及回归线

注 回归线只能描述“平均而言”的关系，不代表每个个体都严格落在线上。而且用回归做预测时，最好只在数据范围 (2-11h) 内外推一点点，别拿它预测“每天学 18 小时”这种离谱情况。

8.4 双变量线性回归

双变量线性回归用两个自变量 x_1, x_2 预测 y ：

$$y = a + b_1x_1 + b_2x_2 + \varepsilon$$

例如，除了“每天学习时间”，再加入“每周复习次数”一起预测日语成绩：

$$\hat{y} = a + b_1 \cdot \text{学习时间} + b_2 \cdot \text{复习次数}$$

双变量回归和单变量回归最大的不同在于：每个系数 b_1, b_2 表示的是在控制另一个变量不变的情况下，该变量每增加一个单位时 y 的平均变化。这就是“控制变量”的思想。

- b_1 ：复习次数不变时，学习时间每多 1 小时，成绩平均变化多少；
- b_2 ：学习时间不变时，复习次数每多 1 次，成绩平均变化多少。

注 如果两个自变量彼此高度相关（比如“学习时间”和“复习次数”本来就一起变），就很难把它们的贡献分清楚，这叫**多重共线性**。变量之间越“独立”，系数的解释越干净。

8.5 多变量线性回归

多变量线性回归把自变量推广到 k 个：

$$y = a + b_1x_1 + b_2x_2 + \cdots + b_kx_k + \varepsilon$$

它的思想和双变量完全一样：每个系数都是在“其他变量不变”的前提下，该变量的单独效应。只是变量一多，事情会变复杂：

- 需要的样本量更大，否则系数估计不稳定；
- 变量之间可能互相纠缠（多重共线性）；
- 塞太多没用的变量容易**过拟合**——在已有数据上拟合得很好，但换一批数据就“失灵”。

实际建模时，通常先用相关系数和散点图观察变量关系，再逐步筛选变量、检查残差，最后用 R^2 、调整 R^2 和 p 值等评估模型。

注 模型不是“变量越多越好”。简单、可解释、经得起新数据检验的模型，往往比塞满变量的复杂模型更有用。

附录 A 各分布的概率临界值表

本附录收录了 t 分布、 χ^2 分布和 F 分布的常用临界值表，供查阅。

A.1 t 分布

t 分布临界值表给出的是：在给定自由度 df 和上尾概率 α 下，满足 $P(T > t_\alpha) = \alpha$ 的临界值 t_α 。查表时先找自由度所在的行，再找对应的 α 列。

表 A.1: t 分布临界值表（上尾概率 α ）

df	0.10	0.05	0.025	0.01	0.005
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
21	1.323	1.721	2.080	2.518	2.831
22	1.321	1.717	2.074	2.508	2.819
23	1.319	1.714	2.069	2.500	2.807
24	1.318	1.711	2.064	2.492	2.797
25	1.316	1.708	2.060	2.485	2.787
26	1.315	1.706	2.056	2.479	2.779
27	1.314	1.703	2.052	2.473	2.771
28	1.313	1.701	2.048	2.467	2.763
29	1.311	1.699	2.045	2.462	2.756
30	1.310	1.697	2.042	2.457	2.750
40	1.303	1.684	2.021	2.423	2.704
60	1.296	1.671	2.000	2.390	2.660
120	1.289	1.658	1.980	2.358	2.617
∞	1.282	1.645	1.960	2.326	2.576

A.2 χ^2 分布

χ^2 分布临界值表给出的是：在给定的自由度 df 和上尾概率 α 下，满足 $P(\chi^2 > \chi^2_\alpha) = \alpha$ 的临界值。

表 A.2: χ^2 分布临界值表（上尾概率 α ）

df	0.10	0.05	0.025	0.01	0.001
1	2.706	3.841	5.024	6.635	10.828
2	4.605	5.991	7.378	9.210	13.816
3	6.251	7.815	9.348	11.345	16.266
4	7.779	9.488	11.143	13.277	18.467
5	9.236	11.070	12.833	15.086	20.515
6	10.645	12.592	14.449	16.812	22.458
7	12.017	14.067	16.013	18.475	24.322
8	13.362	15.507	17.535	20.090	26.125
9	14.684	16.919	19.023	21.666	27.877
10	15.987	18.307	20.483	23.209	29.588
11	17.275	19.675	21.920	24.725	31.264
12	18.549	21.026	23.337	26.217	32.910
13	19.812	22.362	24.736	27.688	34.528
14	21.064	23.685	26.119	29.141	36.123
15	22.307	24.996	27.488	30.578	37.697
16	23.542	26.296	28.845	32.000	39.252
17	24.769	27.587	30.191	33.409	40.790
18	25.989	28.869	31.526	34.805	42.312
19	27.204	30.144	32.852	36.191	43.820
20	28.412	31.410	34.170	37.566	45.315
21	29.615	32.671	35.479	38.932	46.797
22	30.813	33.924	36.781	40.289	48.268
23	32.007	35.172	38.076	41.638	49.728
24	33.196	36.415	39.364	42.980	51.179
25	34.382	37.652	40.646	44.314	52.620
26	35.563	38.885	41.923	45.642	54.052
27	36.741	40.113	43.194	46.963	55.476
28	37.916	41.337	44.461	48.278	56.892
29	39.087	42.557	45.722	49.588	58.301
30	40.256	43.773	46.979	50.892	59.703

A.3 F 分布

F 分布临界值表给出的是：在给定分子自由度 df_1 、分母自由度 df_2 和显著性水平 α 下，满足 $P(F > F_\alpha) = \alpha$ 的临界值。下表为 $\alpha = 0.05$ 的常用临界值。

表 A.3: F 分布临界值表 ($\alpha = 0.05$)

$df_2 \backslash df_1$	1	2	3	4	5	6	8	10	12	15	20	30	60	∞
1	161.45	199.50	215.71	224.58	230.16	233.99	238.88	241.88	243.91	245.95	248.01	250.10	252.20	254.32
2	18.51	19.00	19.16	19.25	19.30	19.33	19.37	19.40	19.41	19.43	19.45	19.46	19.48	19.50
3	10.13	9.55	9.28	9.12	9.01	8.94	8.85	8.79	8.74	8.70	8.66	8.62	8.57	8.53
4	7.71	6.94	6.59	6.39	6.26	6.16	6.04	5.96	5.91	5.86	5.80	5.75	5.69	5.64
5	6.61	5.79	5.41	5.19	5.05	4.95	4.82	4.74	4.68	4.62	4.56	4.50	4.43	4.38
6	5.99	5.14	4.76	4.53	4.39	4.28	4.15	4.06	4.00	3.94	3.87	3.81	3.74	3.68
7	5.59	4.74	4.35	4.12	3.97	3.87	3.73	3.64	3.57	3.51	3.44	3.38	3.30	3.24
8	5.32	4.46	4.07	3.84	3.69	3.58	3.44	3.35	3.28	3.22	3.15	3.08	3.01	2.95
9	5.12	4.26	3.86	3.63	3.48	3.37	3.23	3.14	3.07	3.01	2.94	2.86	2.79	2.73
10	4.96	4.10	3.71	3.48	3.33	3.22	3.07	2.98	2.91	2.84	2.77	2.70	2.63	2.57
12	4.75	3.89	3.49	3.26	3.11	3.00	2.85	2.75	2.69	2.62	2.54	2.47	2.40	2.34
15	4.54	3.68	3.29	3.06	2.90	2.79	2.64	2.54	2.48	2.40	2.33	2.25	2.18	2.12
20	4.35	3.49	3.10	2.87	2.71	2.60	2.45	2.35	2.28	2.20	2.12	2.04	1.95	1.88
30	4.17	3.32	2.92	2.69	2.53	2.42	2.27	2.16	2.09	2.01	1.93	1.84	1.75	1.68
60	4.00	3.15	2.76	2.53	2.37	2.25	2.10	2.00	1.92	1.84	1.75	1.65	1.53	1.46
∞	3.84	3.00	2.60	2.37	2.21	2.10	1.94	1.83	1.75	1.67	1.57	1.46	1.32	1.00