

豆知識—統計学

(2025/12/13 1st ed)

目次

前書き	2
本书内容	2
写书契机	2
一些建议	2
私が見る統計学	3
数据与统计	3
完整的统计步骤	4
相关不蕴涵因果	5
参数和统计量	6
样本采集——抽样方式及最佳组数	7
正态分布及自由度	8
离散数据类型及分布	9
连续数据类型及分布	10
假设检验与p值解读	11
非技术用语的假设检验总结模板	12
置信区间	13
相关性、系数与回归	14
独立性检验与列联表（卡方检验）	15
配对卡方检验	16
三种t检验	17
F检验与单、双因素方差分析	18
双因素方差分析	19
日本語言語学について	20
言語学としての日本語	20
面白い言語学	20
日本語言語学と統計	20
後書き	21
一点想法	21
参考文献	21

前書き

本书内容

翻开这本书的人，或多或少与外语有关。本书主要介绍统计学相关的基础知识，但也有时会涉及到日语语言学。本书的核心内容在第三部分「私が見る統計学」，每小节以：数据对象—专业术语集[—数据分析]的形式呈现。同时侧边大纲栏、索引帮助读者快速找到想要的内容。

写书契机

与其说是书，不如称之为了一本“知识手册”，其中总结了一些学习统计学的心得，以及“我眼中的统计学”。在本学期开学前，作者自学了一些概率论与数理统计，本以为能从从容容地应付下述课程，结果却让我大为惊叹。此时距离《语言研究中的统计学》这门课结束还有半个月，距离托业考试还有一月余五天，最近无心学习，所以才有时间写这本小册子。

今年是学习日语的第6年，第一次尝试写知识手册，不过请读者诸位放心，全文无杜撰，无毒，大可放心“食用”。那么，为什么写这本书？答案很简单：为了方便。就如同日语中为了发音便利而产生了「音便」一般。数周前，一位朋友向我请教一些统计学上的问题，大概是关于F分布和p值，我本以为能够清晰简明地解释，但并非如此，于是我再次翻开了参考书籍；几天前，和另一位朋友闲聊时，涉及到“统计学”时，不禁感叹道：“本来**就没啥说服力,全靠吹气球”，如果不引用一点方法，那便真正陷入了循环论证，遂萌发了将部分所学记录下来的念头。

此书写给自己和我的朋友们，共同进步。

欢迎各位读者批评，指正，本“知识手册”长期更新，直至成为一本书。作者邮箱：z234s@outlook.com。如果本书给任何人提供了学习上的便利，便是我最大的荣幸。

一些建议

以下是一些阅读本书的建议：

- 虽不需要太多数学知识，但建议了解，学习一些基础概念和计算，这并不是坏事。
- 本书会在术语首次出现时解释说明，后不再赘述，建议添加标签、笔记。
- ☞符号标记为分析案例，建议动手尝试，不要只看不做，那没有用。
- 由于作者水平、认知有限，★符号标记的内容仅为作者的见解，建议读者自查相关资料。
- 感到迷惑时立即停下，你需要补充相关知识，回头看看。基础不牢，地动山摇。
- 不想读时立即停下，你需要休息。

数据与统计

什么是统计学？统计学（Statistics）是一门研究数据收集、整理、分析、解释和呈现的科学，旨在从数据中提取信息、发现规律并支持决策。所以在这节内容开始之前，还需要思考一件事，即什么是数据「データ」？注：本书分别用数据和数据集指代单个样本数据和一组样本数据。

不难看出，“数据”就是统计这一行为的研究对象。我们可以自然地想到，（1，3，5，9）这样一串数字是数据，某次考试班级同学的成绩“96、67、81、74...”也是数据。容易让人出乎意料的是：数据不仅限于“数字”，一段“文字”也可以是数据，例如：你今天说过的日语句、某位同学对某位老师所授课程的看法、评价等等。换句话说，★数据即可观测，可处理的信息载体。只要应对得当，甚至可以认为存在的一切都是数据，而不仅限于“数字”本身。

接下来，对数据的分类及其特征作简要概述：

类别	特点	示例	有意义的操作
名义（分类）	仅区分类别，无数量	男/女；产品型号等	频数、众数
排序（分类）	按某种条件的排序号	成绩排名，高校等级	中位数，百分位数
标量（定量）	数量，即计数，测量	363（天），十万（円）	加减乘除、均值、方差等

以上三分类是为方便理解进行的简单分类，详细可参照“经典四分类”（Stevens, 1946），即根据数据的测量尺度对数据进行分类。事实上，还可按照数据是否结构化、是否离散或连续等条件进行更加复杂的分类。需理解：

- 1. 名义测量尺度的数据有时会简单地直接按数字“1，2，3...”分类，这是为了方便做记录和统计软件进行数据分析，但你应该时刻记住这是“名义数据”！
- 2. 排序类的数据仅做排序使用，用于展现一组礼儀正しい数据，有时可按排序作数据筛选。☹但对排序号求均值和差值是无意义的。同时相比其他类型，蕴含的信息有限。
- 3. 标量数据是最为常见的数据类型，还可按照有无绝对零点细分为定比测量尺度和定距测量尺度。显而易见，标量数据之间的加减乘除操作大多是有意义的，例：363（天）*十万（円）= 一个千万富翁（开玩笑的，理解了就好）。

需注意：数据的分类尤为重要，这直接关系到甚至整个统计过程。

好，上述已简要概述数据类型，☹请思考如何将你的“午餐”转换为一组数据，如果你还没吃，或许先思考中午吃什么会是个更好的问题。

完整的统计步骤

以下展示如何整理，分析，呈现数据，这也是统计研究的核心。

准备阶段

首先确定一个研究目标，为什么需要进行统计？

收集数据——采用合适的采样方法，公正地选取数据来源

处理数据——找出并合理记录有效数据，注意区别那些离谱的数据



分析阶段

初步绘图或总结成表格，并剔除异常值

合理汇总，分组数据，并以此确定统计量

根据计算出的统计量判断数据分布、特征，分析统计结果



总结阶段

根据分析的结果确定研究是否具有统计显著性

汇总图表和文字描述，撰写统计研究的结论

采用合适的形式呈现统计过程和最终结论

完整的统计步骤应包含准备、分析、总结这三个阶段，但有时会因研究对象的复杂性，研究目的的多样性而不仅限于此。


相关不蕴涵因果

什么是相关性？什么是因果？如果A，则B，那么二者就是因果关系。相关则是指二者之间存在关联，这种关联的强度、是否受到其他因素的影响都是待确定的。

入冬后，某商场短款羽绒服的销量逐渐上升，与此同时同地区某医院里的骨折人数也在增加，似乎呈现某种相关关系：

日期	11. 05	11. 20	12. 05	12. 20	1. 05
羽绒服销量	3	5	9	10	10
骨折人数	2	3	5	6	7

如果将上述表格制成线性图：



根据上图羽绒服销量和骨折人数的折线趋势图，或使用统计软件进行分析，似乎很容易得出二者之间存在线性相关关系的结论，而且还具有相当高的相关系数 r 。然而从常理来说，卖出数件羽绒服会导致同地区的一个“幸运儿”骨折，这显然是荒谬的。

- 首先，我们在对数据集进行统计时需要时刻牢记三件事：
- 相关性并不意味着因果关系。**就上例而言，即使这世界上真的有恶趣味神灵，针对那些买羽绒服的人，使他们骨折，使得二者相关性无限接近于1，我们也不能说卖出羽绒服必然导致骨折。毕竟这只是一个统计过程，并不能简单地对应到现实世界的因果关系。
 - 时刻注意伪相关和容易被忽略的因素。**伪相关指那些在纸面(或软件)数据分析上十分合理，但在实际中无明显关联的关系。以上就是一个很好的例子，相似的还有：冰淇淋的销量和溺亡人数、年度新生儿的数量与巧克力的产量等等。许多伪相关都指向那些被忽略的因素,比如冬季低温，羽绒服销量自然会比往常要多，气温越低销售量越高，同时地面更容易结冰，摔骨折的概率也比一般情况要高。致使冰淇淋销量和溺亡人数对应增长的真正因素是夏季的高温，试着说明为什么？
 - 不要预设结论。**试猜想，棉服生产商在看到数据后，更容易得出以上荒谬结论，因为厂家希望别人购买自家棉服，而不是别家的羽绒服。所以统计应从一个现象或公正的假设出发，采取合理的分析方法。在总结结论之前你拥有足够多的时间和方法规整数据集，改进统计方法，以完善自己的统计研究，而不是漠视一切，朝着心中已有的一个“结论/目标”闷头前进。确实，有时样本数据和统计结果统计结果只能差强人意，这时你应该“绕远路”，而不是“直线前进”。

参数和统计量

参数是描述总体某些特征的数值度量。

统计量是描述样本某些特征的数值度量。

通常来说，在研究一个课题时，我们无法将涉及到的所有研究对象纳入其中，只能退而求其次，即公平公正地采取一小部分对象，用它来代表整个总体。如果你的课程教师让你统计分析N1分数与性别之间是否存在关联,你会去收集记录这世界上所有男性与女性的N1成绩吗？这当然不现实，一个好的方案是：从参与N1考试的总体对象中随机抽取各个人群中的一部分人构成样本。当然，样本集中样本的来源越广泛，总数越多，越能够代表总体，但我们需要考虑成本和效率。★事实上，当样本初具规模时，就已经能够很好地表现总体。

以下是常用的参数/统计量：

均值	一组数据的平均值，即将一组数据中的数字求和，再除以个数	$\bar{x} = (x_1+x_2+\dots+x_n)/n$
方差	数据偏离均值的程度，或称离散程度。 方差越小，各个数据之间越趋同	$S^2 = [(x_1-\bar{x})^2+...+(x_n-\bar{x})^2]/(n-1)$
偏度、峰度		正偏：右尾长；负偏：左尾长 高峰：尖峰；低峰：平峰
$\chi^2(n)$	检验分类变量的独立性或分布拟合	用于卡方检验
t(n)	检验样本均值是否等于某个值	用于t检验
F(m,n)	比较两个方差或多个组均值差异	用于方差分析

需注意：并非所有统计量都像均值、方差那样好理解，以至于我们能够直接理解其数值代表的对象和关系。例如卡方—— $\chi^2(n)$ 这一统计量是“独立标准正态变量的平方和”，包括后面更加复杂的t分布、F分布，都与正态分布有极大的关系。右侧小括号中的字母或数字代表自由度，后述。☞思考一下，为什么我们需要那么多的统计量？仅均值、方差、分位数、众数等统计量不够吗？

样本采集——抽样方式及最佳组数

在确定研究目标和研究对象后，下一步就要进行样本采集，不论是为何种目的，在收集数据前，需坚守一个最大前提：即收集一个简单随机样本。以下是其他常用的抽样方法：

系统抽样(也称为等距抽样或机械抽样)是指先从总体中选择某个起点，然后按相等的距离或间隔(如每隔50个)从中抽取个体。

分层抽样是指先将总体细分为至少两个不同的子群(或层级)，同一子群中的个体具有相同的特征(如相同的性别)，然后从每个子群中抽取个体。

整群抽样是指先将总体划分为若干区块(或集群)，然后从这些区块中随机选取至少一个区块。最后的样本即为这些所选取的区块中所有的个体。


根据★斯透奇斯规则，N个数据的最佳组数可以确定为： $M = 1 + (\log N) / (\log 2)$ 。由此可确定，每组的组间距为：（数据最大值-数据最小值）/组数。

正态分布及自由度

我觉得是时候引入分布和自由度的概念了。

如果你是个细心观察的人，你会发现这个世界上的许多事物看起来都是“中规中矩”的，即不会过分多也不会过分少，不会过分地高，也不会过分地低。大部分对象都落在了这个“中规中矩”的区间里，只有极少数值离奇的高或低，如果画一张频度直方图，那就像是倒过来的钟。例如正常参加N1考试，考180分的人和考30分的人一样稀少。我想以上就是关于符合正态分布对象的最佳描述。★在总体中，每个个体都有自己所处的“位置”，而每个个体所处位置对应的值具有规律性。

“分布”描述某个（个体）变量的值以及在不同取值上的出现概率。所以不必懊恼自己不是180的彭鱼晏或美丽动人的刘亦非，至少你也没有长成咕噜不是吗。



以上是N1考试的成绩直方图，样本成绩总体服从正态分布，可以看出大部分人的成绩都在40-140分之间，整体呈现左偏态，左长尾。因为报名考试的人大多认真努力准备了考试，所以整体分数会倾向于右侧高分区间。

现在我们来思考一件事：如果已知一个6人小组的平均成绩，至少需要知道几人的成绩才能准确说出每个人的成绩？答案很明显，是5人。因为在我们知道倒数第二个人的成绩之前，最后一个人的成绩都是未知的，那么一旦我们知道了前n-1个人的成绩，整组成绩（数据）将不能再自由变动。通俗来讲，前面n-1人的成绩都是随即任意的，因为有最后一个人“兜底”，负责保证平均值对的上，就“万事大吉”了。以上n-1（样本量-1），即df，[自由度](#)。

但统计研究时常常会分多个（m）组，每个组有n个个体，试着说明这组数据的df = 2*3 = 6。

x	q	l	p
b	e	s	v
c	h	z	u

离散数据类型及分布

在第一节数据与统计中，我们对数据进行了简单分类，实际上也可按照数据是否连续，分为离散数据类型和连续数据类型，对应的有离散概率分布和连续概率分布。

离散概率分布中，常见的有“0-1分布”（“伯努利分布”），“二项分布”，“泊松分布”。

0-1分布

二项分布

泊松分布

连续数据类型及分布

连续概率分布中，常见的有“均匀分布”，“正态分布”，“ χ^2 分布”，“t分布”，“F分布”。

均匀分布

卡方分布

t分布

F分布

假设检验与p值解读


如何证明并非世界上所有的人都是女人，是个正确的论断，尽管所有人都知道这个事实？

就像是情侣之间问爱不爱一样，很难证明爱，有多爱，但是经常因为一些小事说出：“你不爱我了”。事实上，证明一件事正确很难，也很麻烦，但证伪就容易多了，只需找到一个反例即可，比如忘了对象的生日（开个玩笑，记不记得纪念日与爱不爱无关）。

那么如何解决开头的问题？最快捷、简便的方法就是：首先假设这世界上的所有的人都是女人，接着努力找到一个反例——一个男人。很幸运，我本人就是男性，所以很容易走到第三步——拒绝原假设，那个“这世界上的所有的人都是女人”的假设。最后我可以自然且轻松地得出结论，并非世界上所有的人都是女人。但是对于我的朋友们来说，情况可能会变得有些复杂。如果环视宿舍会发现，全都是女性（这是理所当然的）！紧接着走出宿舍，仍然遇见的全是女性，如果运气不佳，可能走遍整个校园都碰不到一位男性，此时要证明开头的假设为真可太难为人了。

相信你已经了解了假设检验的具体含义，但还是让我用一个例子来做总结：

初看某张期末成绩表，男同学的体育成绩高于大多数女同学5分，现在想探究男女之间体育成绩是否真的存在差异。



通常在假设检验中，只有较小的p值才能得出有意义的结论，🤔思考一下为什么？

置信区间

相关性、系数与回归

在前面的章节中提到过, 相关不蕴涵因果。那么什么又是相关? 该如何度量相关性?

简单来讲, 相关即有关联。如果在统计学上说A、B二者具有相关性, 则表明其中一方在数据上发生变化时会引起另一方的变化, 这种关系的强度可以用[相关系数](#) r 来表示。

在说明“回归”概念前, 请先随手写下一个一元一次函数。我写的是 $y = 3x + 1$, 这表示 x 每增加1单位, y 对应增加3单位。回归与函数很像, 用于研究一个因变量与其他一个或多个变量(自变量)之间的关系, 尤其是定量关系。最简单的形式: 一元线性回归, 用于根据自变量预测因变量的值, 一个简单的表达式可以写作: $\hat{y} = \hat{a}x + \hat{b}$ 。其中 $\hat{a}$ 、 $\hat{b}$ 都是估计值, 也就是说线性回归并不像一元一次函数那样“一对一”地准确, 回归出来的结果与实际值可能存在误差。

相关系数 r 表示两个变量之间的线性相关程度, [决定系数](#) R^2 表示回归模型解释的变异比例, 在简单线性回归中, $R^2 = r^2$ 。

独立性检验与列联表（卡方检验）

列联表（或称双因子频数表）是指分类数据按两个变量（一个行变量，另一个为列变量）构成的频数表。独立性检验即检验列联表中两个变量之间的独立性。

列联表的独立性检验所对应的是 $\chi^2(n)$ 分布。下表是一个很好的例子，可用于探究年龄段与运动偏好两个变量之间的独立性（是否有关联）：

这是一个行变量

	跑步	球类	骑行
青年	13	23	12
中年	16	21	8
老年	7	35	6

这是一个列变量

首先作出假设 H_0 ：年龄段与运动偏好无关，具体的统计过程可使用统计软件，得出结果 $\chi^2(4)=9.902$ ，下一步便是去查找卡方分布表中 $df=4$ 时， χ^2 统计量等于9.902的那个概率值 p 。因为内容有限，一般的分布表不会完整记录每个自由度对应的所有统计量的值和概率 p ，但幸运的是 $\chi^2(4)=9.448$ 时， $p=.05$ ，我们拥有更大的卡方统计量，所以对应的 p 值会更小，即 $p[\chi^2(4)=9.902]<.05$ ，那么我们有足够的理由拒绝原假设 H_0 ，得出结论：年龄段与运动偏好有关。

以上便是3*3两个因素之间的独立性检验，当然更常见的是2*2两个因素之间的独立性检验，比如性别和健不健身是否有关。此处我插入了一个更为复杂的表，以便读者真正理解了列联表的独立性检验。

配对卡方检验

如果2*2表格中的频数来自配对样本，那么显然不能使用独立性检验。这种情况下应该使用配对卡方检验，其原假设为两组不一致类别（即结果不同的类别）的频数比例（发生概率）相同。简单来说：1. 数据是配对的（同一个对象在两种条件下被测量）；2. 变量是二分类变量（如“是/否”、“成功/失败”、“阳性/阴性”）；3. 想检验的是：两种条件下的分类结果是否一致。

举个例子：某一药物治疗前后效果比较：

	治疗前有症状	治疗前无症状
治疗后有症状	10	5
治疗后无症状	20	15

首先假设 H_0 ：这种药物治疗无效。同样使用统计软件计算出 $\chi^2(1) = 9$ ，这远大于 $p = .05$ 时 $\chi^2(1) = 3.841$ ，和上一节相似，我们较大的卡方统计量，因此得到更小的p值。这意味着，在假设药物无效的前提下，我们采集到以上样本的概率远小于.05，所以我们同样拒绝原假设 H_0 ，最终得到这种药物治疗确实有效的结论。

三种t检验

单样本t检验

独立样本t检验

配对样本t检验

单样本t检验	一组样本 vs 已知总体均值	判断样本均值是否 等于某个已知值	$Df = n-1$
独立样本t检验	两组独立样本	比较两个独立组的 均值差异	$Df = n_1+n_2 - 2$
配对样本t检验	两组配对样本（同一对 象前后测量）	比较同一组在两种 条件下的差异	$Df = n-1$

单因素方差分析与F检验

单因素方差分析（ANOVA）用于检验3个或3个以上总体的均值是否相等。单因素方差分析可以用一个因素（或因子）对数据进行分类。原假设 H_0 ：被分类的样本的总体均值都相等（也就是说它们来自均值都相等的总体），可简记为： $\mu_1=\mu_2=\dots=\mu_n$ 。

示例：从4个班中各随机抽取6名学生，记录他们的期末成绩于以下表格：

1班	2班	3班	4班
66, 73, 82, 69, 95, 79	83, 73, 93, 77, 58, 79	60, 90, 77, 79, 88, 62	74, 73, 65, 87, 78, 66

首先假设 H_0 ：被分类的样本的总体均值都相等，即1、2、3、4班平均成绩无差异。☛接下来使用统计软件进行分析，得到统计量 $F(3, 20) = ?$ ，查表得知对应的 $p[F(3, 20) = ?] = \alpha, \dots$ ，所以我们...原假设，最终得到结论这4个班的成绩是有/没有差异的。

注：F分布、统计量与其他分布、统计量不同，它有两个自由度，前一个自由度 df_1 =样本数（组数）-1；后一个自由度 df_2 =样本数（组数）*（每组样本数量-1），所以上述F检验中自由度分别为4(个班)-1=3，和4(个班)*(6-1)=20。此外需注意使用此检验应保证每个样本(班)中样本量相等。

双因素方差分析与F检验

双因素方差分析与单因素方差分析最大的区别在于，有两个因素变量，不再只是一个分类。使用双因素方差分析方法，我们需要先根据两个因素将数据集“纵横”分为两类(有点像从横竖两个方向切蛋糕)。分完类以后需要检验这两个因素之间有无交互作用，再检验两个因素是否分别具有主效应。以下示例工作日、职业两个因素变量下记录的每日光照时间(min)，每个样本中含6人：

	周一	周二	周三	周四	周五
教师					
学生	30, 14, 55, 21, 39, 18				
外卖员					

☞试着自己补充以上表格，并用统计软件，
首先分析职业与工作日是否有交互作用，共同影响每日光照时间。如果有，则检验结束，无需考虑因素的主效应（事实上此时也无法考虑，想想为什么？）。
如果两因素变量没有交互作用，再分别检验职业因素是否具有主效应（影响每日光照）、工作日因素是否具有主效应（影响每日光照）。
最终汇总结论。

日本語言語学について

言語学としての日本語

音韻、単語、文法。

言語学の面白さ

情報を伝達、自然语言的独特。

日本語言語学と統計

後書き

一点想法

参考文献